INTRODUCCIÓN A LA CIENCIA DE DATOS

**Etapa 1 - Inicial**

# Proyecto Macroeconomía



LETICIA CÁRPENA, MARÍA PAZ GARCÍA Y PAULINA GERICKE

*¿Qué factores socioeconómicos explican las diferencias en el nivel de actividad económica entre los departamentos de Uruguay? Período (2006-2023)*

# CONFIGURACIÓN INICIAL

## en Google Collab

```
[1]
✓ 2 s
```

```python
import re
from pathlib import Path

import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats

# ============================================================
# CONFIGURACIÓN
# ============================================================
DATA_DIR = Path("./data")
OUT_FIG_DIR = Path("./figuras")
OUT_FIG_DIR.mkdir(exist_ok=True)

FILES = {
    "desempleo": DATA_DIR / "desempleo.csv",
    "ingreso": DATA_DIR / "salario.csv",
    "pobreza": DATA_DIR / "pobreza.csv",
    "educacion": DATA_DIR / "educacion.csv",
    "esperanza_vida": DATA_DIR / "esperanza_vida.csv",
    "puerto": DATA_DIR / "puerto.xlsx",
}

sns.set_theme(style="whitegrid")
plt.rcParams["figure.dpi"] = 110
```

1. **Importamos las librerías necesarias**

- **re** → trabajar con patrones de texto
- **path** → manejar carpetas y archivos
- **pandas** → leer y trabajar con bases de datos
- **numpy** → hacer cálculos numéricos
- **matplotlib y seaborn** → crear gráficos
- **scipy stats** → realizar cálculos y análisis estadísticos

2. **Definimos en dónde están los datos y en dónde guardar los gráficos**

- Los datos están en la carpeta “**data**”
- Los gráficos que genere se guardan en la carpeta “**figuras**”

3. **Creamos un diccionario que permite acceder a cada base de datos**

- Datos sobre **desempleo**, **salario**, **pobreza**, **educación**, **esperanza de vida** y **existencia de un puerto**.

4. **Configuramos cómo se van a ver los gráficos**

- **whitegrid** → fondo blanco
- **dpi = 110** → mejora la calidad de las figuras.

# CARGAR DATOS

Subir archivos

```
from google.colab import files
import shutil
```

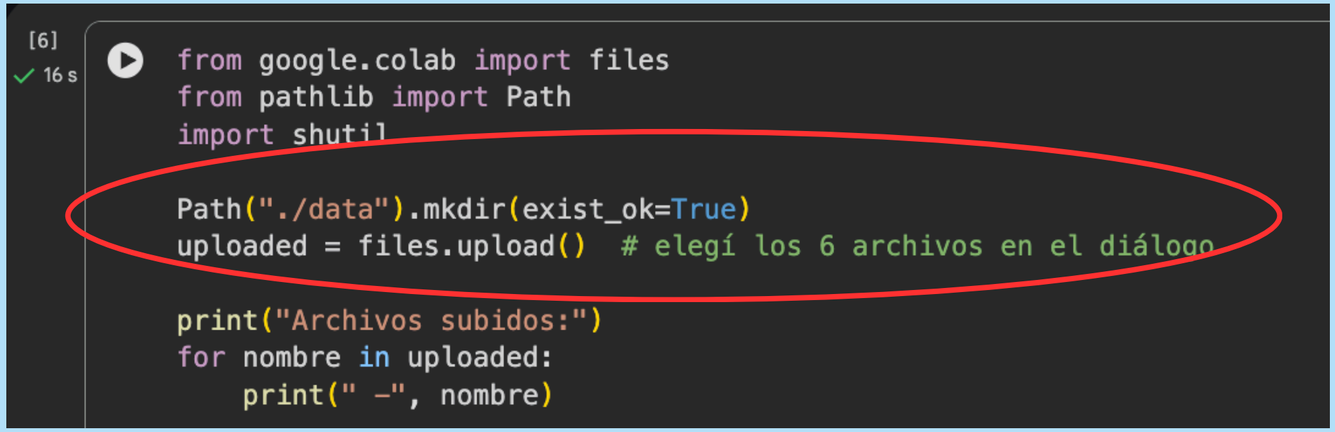
- **from google.colab import files**: importamos la herramienta files de Google Collab para seleccionar y subir los archivos al entorno de trabajo.

- La librería **Path** es una herramienta de Python que permite trabajar con rutas y carpetas de forma sencilla. La utilizaremos para crear la carpeta donde guardaremos los datos.

- **import shutil:** importamos la librería para poder mover y organizar los archivos una vez estén cargados.

# CARGAR DATOS

- **Path("./data"):** indica la ruta de la carpeta que queremos crear. ./ representa el directorio actual.
- **.mkdir():** es el método que crea la carpeta.
- **exist_ok=True:** permite que el código continúe ejecutándose aunque la carpeta ya exista. De esta manera, evitamos que aparezca un error si la carpeta fue creada anteriormente.
- **uploaded = files.upload():** abre una ventana donde podemos seleccionar los archivos para el análisis.
- El resultado de files.upload() se guarda en la variable uploaded. Esta variable contiene los nombres y los datos asociados a cada archivo.



# CARGAR DATOS

Facilitar lectura

- **for nombre in uploaded:** crea un ciclo que recorre cada uno de los archivos almacenados en uploaded. En cada repetición, nombre representa el nombre de un archivo.

- **print(" -", nombre):** imprime el nombre de cada archivo, precedido por un guion, para facilitar su lectura.

- Así, podemos comprobar visualmente qué archivos fueron seleccionados y cargados correctamente.

```
[6]
✓ 16 s
from google.colab import files
from pathlib import Path
import shutil

Path("./data").mkdir(exist_ok=True)
uploaded = files.upload()  # elegí los 6 archivos en el diálogo

print("Archivos subidos:")
for nombre in uploaded:
    print(" -", nombre)
```

```
Elegir archivos 6 archivos
cdd proyecto - desempleo.csv(text/csv) - 2674 bytes, last modified: 15/9/2026 - 100% done
cdd proyecto - educacion.csv(text/csv) - 17969 bytes, last modified: 15/9/2026 - 100% done
cdd proyecto - esperanza de vida.csv(text/csv) - 733 bytes, last modified: 15/9/2026 - 100% done
cdd proyecto - pobreza.csv(text/csv) - 2665 bytes, last modified: 15/9/2026 - 100% done
cdd proyecto - puertos.xlsx(application/vnd.openxmlformats-officedocument.spreadsheetml.sheet) - 5469 bytes, last modified: 15/9/2026 - 100% d
cdd proyecto - salarios.csv(text/csv) - 4255 bytes, last modified: 15/9/2026 - 100% done
Saving cdd proyecto - desempleo.csv to cdd proyecto - desempleo.csv
Saving cdd proyecto - educacion.csv to cdd proyecto - educacion.csv
Saving cdd proyecto - esperanza de vida.csv to cdd proyecto - esperanza de vida.csv
Saving cdd proyecto - pobreza.csv to cdd proyecto - pobreza.csv
Saving cdd proyecto - puertos.xlsx to cdd proyecto - puertos.xlsx
Saving cdd proyecto - salarios.csv to cdd proyecto - salarios.csv
Archivos subidos:
 - cdd proyecto - desempleo.csv
 - cdd proyecto - educacion.csv
 - cdd proyecto - esperanza de vida.csv
 - cdd proyecto - pobreza.csv
 - cdd proyecto - puertos.xlsx
 - cdd proyecto - salarios.csv
```

# CARGAR DATOS

Mapeo

- MAPEO es un diccionario de Python que relaciona un nombre corto identificativo, definido por nosotras, con el nombre original de cada archivo cargado, para reconocer cada conjunto de datos.

- Los valores son los nombres reales de los archivos que subimos a Google Colab.

- DESTINOS es un segundo diccionario que establece el nombre que tendrá cada archivo una vez organizado dentro de la carpeta data. Relaciona cada archivo original con su nuevo nombre.

```
MAPEO = {
    "desempleo":       "cdd proyecto - desempleo.csv",
    "ingreso":         "cdd proyecto - salarios.csv",
    "educacion":       "cdd proyecto - educacion.csv",
    "pobreza":         "cdd proyecto - pobreza.csv",
    "esperanza_vida":  "cdd proyecto - esperanza de vida.csv",
    "puerto":          "cdd proyecto - puertos.xlsx",
}

DESTINOS = {
    "desempleo": "desempleo.csv",
    "ingreso": "salario.csv",
    "pobreza": "pobreza.csv",
    "educacion": "educacion.csv",
    "esperanza_vida": "esperanza_vida.csv",
    "puerto": "puerto.xlsx",
}

for rol, nombre_real in MAPEO.items():
    shutil.copy(nombre_real, Path("./data") / DESTINOS[rol])
```

# PROBLEMAS CON LOS DATOS

```
============================================================
ARCHIVO: esperanza_vida
============================================================
Dimensiones: (9, 1)
Columnas: [',,,,,,,,,,,,,,,,,,,,,,,,,,,,,']

Primeras 5 filas:
   ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
0  ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
1  ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
2  ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
3  ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
4  ,,,,,,,,,,,,,,,,,,,,,,,,,,,,,
```

- **Esperanza vida: SOLO 72 observaciones disponibles (dataset incompleto, no representativo de todos los departamentos)**
- **Ahora estamos evaluando eliminar este archivo del proyecto por consecuencia.**

# PROBLEMAS CON LOS DATOS

```
============================================================
ARCHIVO: puerto
============================================================
Dimensiones: (21, 3)
Columnas: ['Unnamed: 0', 'Unnamed: 1', 'Unnamed: 2']

Primeras 5 filas:
   Unnamed: 0    Unnamed: 1    Unnamed: 2
0         NaN           NaN           NaN
1         NaN  Departamento  Puerto (1/0)
2         NaN       Artigas             1
3         NaN     Canelones             0
4         NaN   Cerro Largo             0
```

- **El archivo Puerto no estaba siendo leído correctamente porque hay columnas sin nombre, pero en realidad el problema es que en el archivo Excel los datos empiezan en la tercera fila, no la primera.**

- **Para solucionar este problema agregamos: header=2 para que comience a leer el archivo desde la fila 3.**

| | A | B | C | D |
|---|---|---|---|---|
| 1 | | | | |
| 2 | | | | |
| 3 | | **Departamento** | **Puerto (1/0)** | |
| 4 | | Artigas | 1 | |
| 5 | | Canelones | 0 | |
| 6 | | Cerro Largo | 0 | |
| 7 | | Colonia | 1 | |

```
============================================================
ARCHIVO: puerto
============================================================
Dimensiones: (19, 3)
Columnas: ['Unnamed: 0', 'Departamento', 'Puerto (1/0)']

Primeras 5 filas:
   Unnamed: 0 Departamento  Puerto (1/0)
0         NaN      Artigas             1
1         NaN    Canelones             0
2         NaN  Cerro Largo             0
3         NaN      Colonia             1
4         NaN      Durazno             0
```

# PROBLEMAS CON LOS DATOS

```
============================================================
ARCHIVO: puerto
============================================================
Dimensiones: (19, 3)
Columnas: ['Unnamed: 0', 'Departamento', 'Puerto (1/0)']

Primeras 5 filas:
   Unnamed: 0 Departamento  Puerto (1/0)
0         NaN      Artigas             1
1         NaN    Canelones             0
2         NaN  Cerro Largo             0
3         NaN      Colonia             1
4         NaN      Durazno             0
```

- **La primera columna estaba vacía en el Excel, por eso no tenía nombre y solo tenía NaN.**

- **Esto lo solucionamos agregando .iloc[: , 1:], para que la primera columna leída sea la segunda (que contiene los datos), y no la primera que esta vacía.**

```
elif archivo.suffix.lower() == ".xlsx":
    df = pd.read_excel(archivo, header=2)
    if nombre == "puerto":
        df = df.iloc[:, 1:]
        df.columns = ["Departamento", "Puerto"]
```

```
============================================================
ARCHIVO: puerto
============================================================
Dimensiones: (19, 2)
Columnas: ['Departamento', 'Puerto']

Primeras 5 filas:
  Departamento  Puerto
0      Artigas       1
1    Canelones       0
2  Cerro Largo       0
3      Colonia       1
4      Durazno       0
```

# ORDENAR Y LIMPIAR

Definimos dos funciones para limpiar, transformar y reutilizar en cada dataset:

```python
def parse_numero_uy(valor):

    if pd.isna(valor):
        return np.nan
    if isinstance(valor, (int, float)):
        return float(valor)
    s = str(valor).strip()
    if s == "" or s.lower() == "nan":
        return np.nan
    s = s.replace(".", "").replace(",", ".")
    try:
        return float(s)
    except ValueError:
        return np.nan
```

- Si el valor está vacío, es NaN o no puede convertirse a número, lo registra como un valor faltante (NaN).
- Convierte los valores numéricos tipo string (texto) a float (decimal)
- Como en Uy se utiliza la coma como separador decimal y el punto como separador de miles, convertimos los datos al lenguaje de Python: solo punto como separador decimal

```python
def cargar_ancho_a_largo(path, value_name, extra_id_cols=None):

    extra_id_cols = extra_id_cols or []
    if path.suffix.lower() == ".csv":
        df = pd.read_csv(path, sep=";", encoding="utf-8-sig")
    else:
        df = pd.read_excel(path)

    df.columns = [str(c).strip().strip('"') for c in df.columns]
    id_cols = ["Departamento"] + extra_id_cols
    year_cols = [c for c in df.columns if re.fullmatch(r"\d{4}", c)]

    largo = df.melt(id_vars=id_cols, value_vars=year_cols,
                    var_name="Año", value_name=value_name)
    largo["Año"] = largo["Año"].astype(int)
    largo[value_name] = largo[value_name].apply(parse_numero_uy)
    largo["Departamento"] = largo["Departamento"].astype(str).str.strip().str.strip('"')
    largo = largo[largo["Departamento"].str.lower() != "total"]
    return largo.dropna(subset=[value_name])
```

- Transforma los datasets de un formato ancho a uno largo para luego facilitar el analisis y poder unirlos
- Define el identificador: Departamento / año
- Elimina la fila "Total" del país y observaciones sin datos.

# CARGA Y RESHAPE DE CADA DATASET

Transformación de las bases de datos

```
desempleo = cargar_ancho_a_largo(FILES["desempleo"], "Desempleo_%")
ingreso = cargar_ancho_a_largo(FILES["ingreso"], "Ingreso_percapita")
pobreza = cargar_ancho_a_largo(FILES["pobreza"], "Pobreza_%")
educacion = cargar_ancho_a_largo(FILES["educacion"], "Educacion_%",
                                 extra_id_cols=["Educación"])
```

- **Definimos las variables:**
  - **desempleo**, **ingreso**, **pobreza** y **educación**
- **Cargamos las bases de datos desde el diccionario FILES**
- **La función cargar_ancho_a_largo transforma los datos de formato ancho a formato largo → hace que los datos sean más fáciles de analizar, combinar y graficar.**

## Antes

| Departamento | 2022 | 2023 | 2024 |
|---|---|---|---|
| Montevideo | 8% | 7% | 7.5% |

## Después

| Departamento | Año | Desempleo_% |
|---|---|---|
| Montevideo | 2022 | 8% |
| Montevideo | 2023 | 7% |
| Montevideo | 2024 | 7.5% |

# CARGA Y RESHAPE DE CADA DATASET

Transformación de las bases de datos

```
# Puerto: indicador cross-sectional (no varía por año) — 1 = el departamento
# tiene puerto, 0 = no tiene.
puerto = pd.read_excel(FILES["puerto"], header=2).iloc[:, 1:]
puerto.columns = ["Departamento", "Puerto"]
puerto["Departamento"] = puerto["Departamento"].astype(str).str.strip()
puerto["Puerto"] = puerto["Puerto"].astype(int)
```

- **Definimos la variable puerto, que determina qué departamentos tienen puerto y cuáles no (binaria). Es cross sectional porque no varía por año.**
- **Cargamos esa base de datos desde el diccionario FILES**
- **Renombramos las columnas como “Departamento” y “Puerto”, convierte los nombres de los departamentos a texto y elimina espacios innecesarios al principio y al final.**
- **Convierte la variable Puerto a números enteros (0 = no tiene puerto; 1 = tiene puerto).**

# CARGA Y RESHAPE DE CADA DATASET

Revisar cobertura datasets

→ **Se verifica la cobertura de cada dataset con nunique() y .min/.max: cantidad de departamentos, años disponibles y categorías.**

**También se identifican datos incompletos (esperanza de vida) y la presencia de puertos por departamento.**

```
print(f"  desempleo:      {desempleo['Departamento'].nunique()} deptos, "
      f"años {desempleo['Año'].min()}-{desempleo['Año'].max()}")
print(f"  ingreso:        {ingreso['Departamento'].nunique()} deptos, "
      f"años {ingreso['Año'].min()}-{ingreso['Año'].max()}")
print(f"  pobreza:        {pobreza['Departamento'].nunique()} deptos, "
      f"años {pobreza['Año'].min()}-{pobreza['Año'].max()}")
print(f"  educación:      {educacion['Departamento'].nunique()} deptos, "
      f"{educacion['Educación'].nunique()} categorías")
print(f"  esperanza vida: SOLO {len(esperanza_vida)} filas disponibles "
      f"(dataset incompleto, no representativo de todos los deptos)")
print(f"  puerto:         {puerto['Puerto'].sum()} de {len(puerto)} departamentos "
      f"tienen puerto")
```

```
Cargando y limpiando datasets...
  desempleo:      19 deptos, años 2006-2024
  ingreso:        19 deptos, años 2006-2023
  pobreza:        19 deptos, años 2006-2023
  educación:      19 deptos, 7 categorías
  esperanza vida: SOLO 72 filas disponibles (dataset incompleto, no representativo de todos los deptos)
  puerto:         11 de 19 departamentos tienen puerto
```

# CARGA Y RESHAPE DE CADA DATASET

Problema educación

**Categorías educación: Sin instrucción, primaria, secundaria, UTU, profesorado, Universidad → problema categoría 'total'**

```
print(f"  desempleo:      {desempleo['Departamento'].nunique()} deptos, "
      f"años {desempleo['Año'].min()}-{desempleo['Año'].max()}")
print(f"  ingreso:        {ingreso['Departamento'].nunique()} deptos, "
      f"años {ingreso['Año'].min()}-{ingreso['Año'].max()}")
print(f"  pobreza:        {pobreza['Departamento'].nunique()} deptos, "
      f"años {pobreza['Año'].min()}-{pobreza['Año'].max()}")
print(f"  educación:      {educacion['Departamento'].nunique()} deptos, "
      f"{educacion['Educación'].nunique()} categorías")
print(f"  esperanza vida: SOLO {len(esperanza_vida)} filas disponibles "
      f"(dataset incompleto, no representativo de todos los deptos)")
print(f"  puerto:         {puerto['Puerto'].sum()} de {len(puerto)} departamentos "
      f"tienen puerto")
```

```
Cargando y limpiando datasets...
  desempleo:      19 deptos, años 2006-2024
  ingreso:        19 deptos, años 2006-2023
  pobreza:        19 deptos, años 2006-2023
  educación:      19 deptos, 7 categorías
  esperanza vida: SOLO 72 filas disponibles (dataset incompleto, no representativo de todos los deptos)
  puerto:         11 de 19 departamentos tienen puerto
```

cdd proyecto - educacion

| Departamento | Educación | 2006 | 2007 | 2008 | 2009 | 2010 | 2011 | 2012 | 2013 | 2014 | 2015 | 2016 | 2017 | 2018 | 2019 | 2022 | 2023 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Montevideo | Sin instrucción | 1 | 1 | 1 | 0,9 | 0,8 | 0,7 | 0,8 | 0,7 | 0,6 | 0,7 | 0,6 | 0,6 | 0,5 | 0,5 | 0,3 | 0,4 |
| Montevideo | Primaria | 31,2 | 29,8 | 29,9 | 29,1 | 27,1 | 23,5 | 24,3 | 24,3 | 22,9 | 22,5 | 22,6 | 20,7 | 19,7 | 19,8 | 16 | 17,4 |
| Montevideo | Secundaria | 32,7 | 33,3 | 32,9 | 32,5 | 33,6 | 32,5 | 33,3 | 33,6 | 34,1 | 34,5 | 35,9 | 34,7 | 35,4 | 35,7 | 37,2 | 36,8 |
| Montevideo | UTU | 11,6 | 11,3 | 13,8 | 13,7 | 13,8 | 14,8 | 13,8 | 13,3 | 13,6 | 13,3 | 13,8 | 13,2 | 12,7 | 11,8 | 9,5 | 10 |
| Montevideo | Magisterio o profesorado | 3,3 | 3 | 2,6 | 2,8 | 2,9 | 2,6 | 2,7 | 2,7 | 2,7 | 2,6 | 2,6 | 2,5 | 2,5 | 2,7 | 3 | 2,7 |
| Montevideo | Universidad o similar | 20,2 | 21,6 | 19,9 | 20,9 | 21,9 | 25,9 | 25,1 | 25,4 | 26,1 | 26,4 | 24,6 | 28,3 | 29,2 | 29,5 | 33,9 | 32,7 |
| Montevideo | Total | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 | 100 |

# Construcción del panel departamento-año

- El **objetivo** es reunir en una **<u>única</u>** tabla la información sobre **desempleo, salarios y pobreza,** incorporando también la variable que indica si el departamento tiene **puerto** y una **clasificación entre Montevideo e Interior.**

- Un panel de datos permite observar **cómo evolucionan diferentes variables** a lo largo del tiempo para las mismas unidades de análisis. En nuestro caso, **las unidades son los departamentos de Uruguay y los años** disponibles en las bases de datos.

| | Departamento | Año | Desempleo_% | Ingreso_percapita | Pobreza_% | Puerto | \ |
|---|---|---|---|---|---|---|---|
| 0 | Montevideo | 2006 | 10.5 | 31701.6 | 32.9 | 1 | |
| 1 | Artigas | 2006 | 14.9 | 13743.9 | 48.9 | 1 | |
| 2 | Canelones | 2006 | 12.1 | 20481.8 | 28.3 | 0 | |
| 3 | Cerro Largo | 2006 | 11.9 | 16331.0 | 42.3 | 0 | |
| 4 | Colonia | 2006 | 7.9 | 20610.2 | 23.3 | 1 | |

# Construcción del panel departamento-año

```
panel = desempleo.merge(ingreso, on=["Departamento", "Año"], how="inner")
panel = panel.merge(pobreza, on=["Departamento", "Año"], how="inner")
```

- Unimos las bases de desempleo e ingresos utilizando el identificador (departamento / año). Con “inner” conservamos únicamente las observaciones que coinciden en ambas bases. Agregamos al panel la variable pobreza.

```
panel = panel.merge(puerto, on="Departamento", how="left")
panel["Interior"] = np.where(panel["Departamento"] == MONTEVIDEO,
                             "Montevideo", "Interior")
```

- Agregamos la variable puerto utilizando el departamento como clave. Con left conservamos todas las observaciones del panel anterior.

- panel["Interior"] = np.where(...): Creamos una variable que clasifica los departamentos en Montevideo e Interior.

# Construcción del panel departamento-año

- Creamos una lista vacía llamada conclusiones, que utilizaremos para ir almacenando los resultados y las conclusiones del análisis.

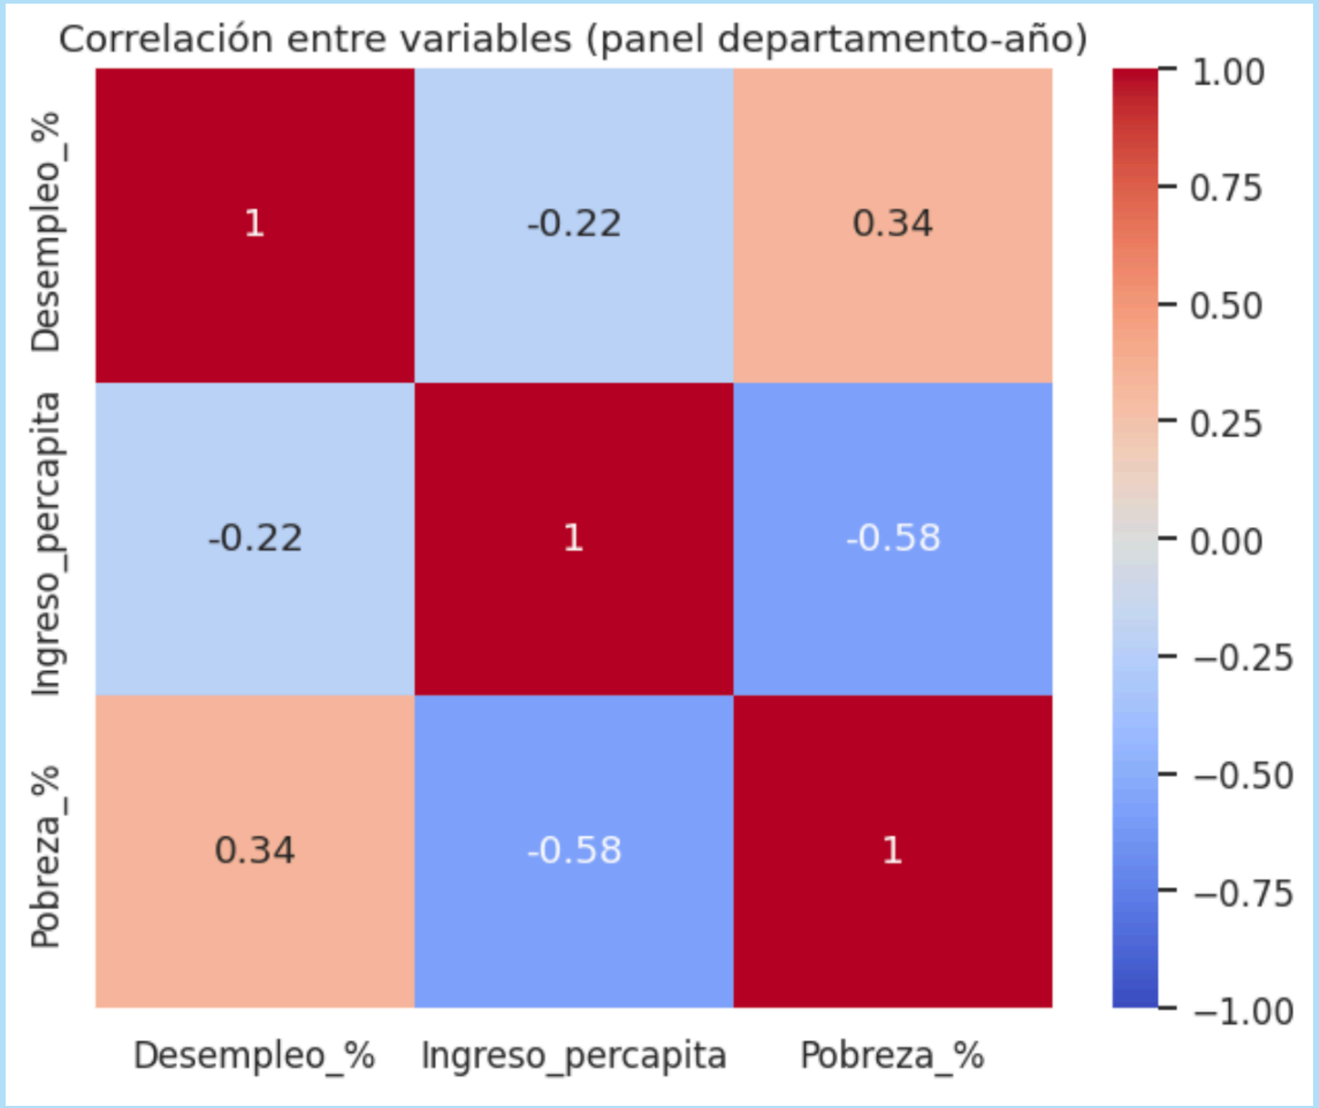
- print(...): Mostramos la cantidad de filas, el período analizado y el número de departamentos incluidos en el panel.

```
conclusiones = []  # acá vamos acumulando las conclusiones para el reporte final
conclusiones.append("=" * 70)
conclusiones.append("CONCLUSIONES DEL ANÁLISIS")
conclusiones.append("=" * 70)

#
```

```
Panel combinado: 342 filas, años 2006-2023, 19 departamentos.
```

# Correlación entre algunas variables



INTRODUCCIÓN A LA CIENCIA DE DATOS

**Etapa 2 - Final**

# Proyecto Macroeconomía



LETICIA CÁRPENA, MARÍA PAZ GARCÍA Y PAULINA GERICKE

*¿Qué factores socioeconómicos explican las diferencias en el nivel de actividad económica entre los departamentos de Uruguay? Período (2006-2023)*

# 1. Estadística descriptiva

```
--- Promedios por departamento (ordenado por actividad) ---
                Actividad  Desempleo_%  Univ_%  Pobreza_%  Ingreso_percapita  \
Departamento
Río Negro            1.43         9.08    6.59      13.65           26733.62
Colonia              1.27         4.99    6.28       8.52           29867.30
Montevideo           1.26         7.79   24.27      18.97           41688.46
Maldonado            1.10         7.02    9.08       6.76           32917.84
Flores               0.99         6.13    5.92       9.01           29056.53
Florida              0.93         6.68    6.38      12.62           27773.75
Soriano              0.92         7.52    6.02      12.76           27954.19
San José             0.92         6.72    5.08       9.95           27700.91
Lavalleja            0.90         7.05    6.09      12.38           27315.40
Treinta y Tres       0.85         8.68    6.08      18.82           24230.22
Rocha                0.84         8.48    5.75      14.42           26064.14
Durazno              0.81         9.86    5.75      16.68           24567.67
Paysandú             0.79         7.47    7.50      15.04           26139.37
Salto                0.74         8.92    9.58      16.88           25268.15
Tacuarembó           0.72         7.35    5.59      18.81           22945.69
Cerro Largo          0.70         6.79    4.58      20.08           20983.19
Rivera               0.67         7.33    5.54      23.09           21600.16
Artigas              0.64         8.82    5.44      24.88           21038.81
Canelones            0.64         7.94   10.88      12.36           29261.29
```

```
MONTEVIDEO = "Montevideo"
# Área metropolitana (sin Montevideo): depar
# Su producción por residente queda baja por
METROPOLITANOS = ["Canelones", "San José"]
```

- **Mayor nivel de actividad promedio**: Río Negro; menor: Canelones.
- **La dispersión entre departamentos es alta** (coeficiente de variación = 25%), lo que confirma la heterogeneidad territorial.
- En el **interior**, los de mayor actividad son Río Negro, Colonia, Maldonado.

```
actividad_depto = panel.groupby("Departamento")["Actividad"].mean()

cv = (
    actividad_depto.std(ddof=1) / actividad_depto.mean()
) * 100

print(f"Coeficiente de variación: {cv:.2f}%")
```

```
Coeficiente de variación: 24.81%
```

# 2. Estadística descriptiva

## ¿Por qué Canelones queda último?

- **Muchos residentes trabajan en Montevideo,** donde se contabiliza su producción, pero viven en Canelones.
- Al combinar ambos departamentos, el VAB per cápita alcanza 1,08, por encima de la media.

## ¿Por qué Colonia supera a Montevideo?

- Su economía **agroexportadora**, industrial y portuaria genera una producción elevada en relación con su población.
- Aunque Montevideo **produce 10 veces más en total, Colonia lo supera levemente por habitante (1,30 vs. 1,27).**

# 3. Tendencias temporales por departamento

```
--- Tendencias ---
              tend_actividad  tend_desempleo  tend_pobreza  tend_ingreso
Departamento
Artigas                0.015          -0.029        -2.089       411.370
Tacuarembó             0.013           0.093        -1.596       379.214
Durazno                0.011           0.139        -1.522       639.546
Rivera                 0.004          -0.027        -1.340       333.569
Salto                 -0.009           0.288        -1.293       499.088
Treinta y Tres         0.013           0.057        -1.285       400.697
Florida                0.012           0.013        -1.205       721.525
Río Negro              0.034          -0.006        -1.193       435.353
San José               0.014          -0.046        -1.191       579.060
Soriano                0.011           0.170        -1.181       470.085
Cerro Largo            0.011          -0.181        -1.172       267.773
Rocha                  0.013           0.076        -1.121       565.884
Paysandú               0.007           0.225        -1.117       456.189
Canelones             -0.002           0.110        -1.105       774.892
Montevideo            -0.008           0.033        -1.089       709.308
Flores                -0.009           0.048        -1.052       595.908
Lavalleja              0.018           0.065        -1.028       468.266
Colonia                0.030           0.139        -0.926       483.440
Maldonado             -0.004          -0.057        -0.578       265.230
```

- Construimos una **tabla** con las **tendencias anuales** de **actividad**, **desempleo**, **pobreza** e **ingreso per cápita** para los 19 departamentos.

- Calculamos la **pendiente** de una **regresión lineal** para identificar si cada variable aumenta o disminuye con el tiempo.

# Principales observaciones

--- Tendencias ---

| Departamento | tend_actividad | tend_desempleo | tend_pobreza | tend_ingreso |
|---|---|---|---|---|
| Artigas | 0.015 | -0.029 | -2.089 | 411.370 |
| Tacuarembó | 0.013 | 0.093 | -1.596 | 379.214 |
| Durazno | 0.011 | 0.139 | -1.522 | 639.546 |
| Rivera | 0.004 | -0.027 | -1.340 | 333.569 |
| Salto | -0.009 | 0.288 | -1.293 | 499.088 |
| Treinta y Tres | 0.013 | 0.057 | -1.285 | 400.697 |
| Florida | 0.012 | 0.013 | -1.205 | 721.525 |
| Río Negro | -0.034 | -0.006 | -1.193 | 435.353 |
| San José | 0.014 | -0.046 | -1.191 | 579.060 |
| Soriano | 0.011 | 0.170 | -1.181 | 470.085 |
| Cerro Largo | 0.011 | -0.181 | -1.172 | 267.773 |
| Rocha | 0.013 | 0.076 | -1.121 | 565.884 |
| Paysandú | 0.007 | 0.225 | -1.117 | 456.189 |
| Canelones | -0.002 | 0.110 | -1.105 | 774.892 |
| Montevideo | -0.008 | 0.033 | -1.089 | 709.308 |
| Flores | -0.009 | 0.048 | -1.052 | 595.908 |
| Lavalleja | 0.018 | 0.065 | -1.028 | 468.266 |
| Colonia | 0.030 | 0.139 | -0.926 | 483.440 |
| Maldonado | -0.004 | -0.057 | -0.578 | 265.230 |

- La **pobreza** **cae** en todos los departamentos: más rápido en Artigas y menos en Maldonado.

- El **desempleo** **no acompañó** esa tendencia, aumentó en **13** departamentos de 19.

- Hay **convergencia**: los departamentos que partían con **más** pobreza son los que más rápido la **redujeron**.

- Departamentos muestran **crecimiento** en términos de **actividad económica per cápita** (**14** de 19), liderado por Río Negro.

# Principales observaciones

**¿Por qué puede bajar la pobreza y subir el desempleo?**

- Porque son **indicadores distintos**.
- La **pobreza** también depende del **ingreso** de los hogares, las transferencias y otros factores.
- Acá encontramos una **relación** interesante:
  - el **ingreso per cápita** aumenta en los 19 departamentos
  - la **pobreza** baja en los 19 departamentos

→ Vemos una **relación inversa** entre el **ingreso** y la **pobreza**.

- Aunque este aumento del **ingreso** no se tradujo en una **reducción** generalizada del **desempleo.**

**Conclusión**: Se observa una mejora generalizada en la pobreza y el ingreso per cápita. Sin embargo, el aumento del desempleo en gran parte del país muestra que estos avances no estuvieron acompañados de una mejora generalizada del mercado laboral.

# 4. Correlaciones con actividad económica

**Promedios por departamento (n = 19)**

```
--- Correlación entre departamentos (promedios, n=19) ---
                  Actividad  Desempleo_%  Univ_%  Pobreza_%  \
Actividad              1.00        -0.22    0.35      -0.51
Desempleo_%           -0.22         1.00    0.09       0.49
Univ_%                 0.35         0.09    1.00       0.06
Pobreza_%             -0.51         0.49    0.06       1.00
Ingreso_percapita      0.65        -0.24    0.82      -0.48
```

```
--- Correlación descontando el año ---
                  Actividad  Desempleo_%  Univ_%  Pobreza_%  \
Actividad              1.00        -0.14    0.32      -0.45
Desempleo_%           -0.14         1.00    0.06       0.37
Univ_%                 0.32         0.06    1.00       0.06
Pobreza_%             -0.45         0.37    0.06       1.00
Ingreso_percapita      0.60        -0.17    0.81      -0.42
```

- El **ingreso per cápita** presenta la mayor correlación positiva con la actividad económica **(r = 0,65)**, mientras que la **pobreza** muestra una correlación negativa moderada (**r = −0,51**).
- La **educación universitaria** presenta una asociación positiva más débil (**r = 0,35**) y el **desempleo**, una asociación negativa débil (**r = −0,22**).
- Al descontar las **variaciones comunes de cada año**, las correlaciones mantienen signos y magnitudes relativamente similares.

# 5. **Diferencias territoriales: Montevideo, interior**

```
--- Montevideo vs. promedio del interior ---
  Actividad: Montevideo=1.26 | interior=0.88 | ratio=1.43
  Desempleo_%: Montevideo=7.79 | interior=7.60 | ratio=1.03
  Univ_%: Montevideo=24.27 | interior=6.56 | ratio=3.70
  Pobreza_%: Montevideo=18.97 | interior=14.82 | ratio=1.28
  Ingreso_percapita: Montevideo=41,688.46 | interior=26,189.90 | ratio=1.59
  ▸ Montevideo tiene 1,43 veces la actividad promedio del interior y 3,7 veces su % con universidad.
  ▸ Aun así, Montevideo es el 4º departamento con más pobreza: concentra la actividad pero también la desigualdad.
```

- Montevideo presenta un **43% más de actividad económica por habitante**, **ingresos per cápita 59% superiores** y una proporción de **población universitaria 3,7 veces mayor** que el promedio departamental del interior.
- A pesar de estos mayores indicadores económicos y educativos, Montevideo registra una **tasa de pobreza superior** (18,97% frente a 14,82%).
- Una mayor actividad económica por habitante no necesariamente está acompañada de menores niveles de pobreza.

# 6. Diferencias socioeconómicas en el interior: con y sin puerto

```
--- Interior con puerto vs. sin puerto (promedios por depto) ---
  Actividad: con puerto=1.01 (n=5) | sin puerto=0.83 (n=13) | p=0.387
  ▸ Interior con puerto (5 deptos) vs. sin puerto (13): actividad 1,01 vs. 0,83 -> diferencia no significativa (p = 0.387).
  Desempleo_%: con puerto=7.79 (n=5) | sin puerto=7.53 (n=13) | p=0.387
  Univ_%: con puerto=7.14 (n=5) | sin puerto=6.34 (n=13) | p=0.117
  Pobreza_%: con puerto=13.70 (n=5) | sin puerto=15.25 (n=13) | p=0.849
  Ingreso_percapita: con puerto=26,814.52 (n=5) | sin puerto=25,949.67 (n=13) | p=0.775
```

- Los departamentos del interior **con puerto** presentan **mayor actividad económica  promedio** (1,01 frente a 0,83), pero la **diferencia no es estadísticamente significativa** (p = 0,387).
- Tampoco se encontraron diferencias estadísticamente significativas en desempleo, educación universitaria, pobreza e ingreso per cápita entre ambos grupos.

# 7. Modelo de actividad económica

```
--- Modelo de actividad ---
                      coef  p_valor  efecto_%_en_actividad  coef_estandarizado
Universidad (%)     -0.009    0.695                 -0.916              -0.176
Desempleo (%)       -0.031    0.164                 -3.076              -0.273
Puerto               0.179    0.177                 19.634               0.755
Montevideo           0.416    0.315                 51.516               1.749
Área metropolitana -0.068    0.593                 -6.542              -0.285
```

- Construimos un **modelo de regresión lineal** para estudiar la relación entre la **actividad económica departamental** y cinco **factores**:
  - educación universitaria
  - desempleo
  - presencia de puerto
  - Montevideo
  - Area metropolitana

```
                    ic95_inf  ic95_sup
Universidad (%)       -1.055     0.703
Desempleo (%)         -0.658     0.112
Puerto                -0.341     1.850
Montevideo            -1.665     5.163
Área metropolitana    -1.328     0.758
R² = 0.30 | 247 obs | 19 deptos
```

```
--- Modelo de actividad ---
                    coef  p_valor  efecto_%_en_actividad  coef_estandarizado
Universidad (%)   -0.009    0.695                 -0.916              -0.176
Desempleo (%)     -0.031    0.164                 -3.076              -0.273
Puerto             0.179    0.177                 19.634               0.755
Montevideo         0.416    0.315                 51.516               1.749
Área metropolitana -0.068   0.593                 -6.542              -0.285
```

- **$R^2$ = 0.30** → El modelo explica el **30%** de la **variación (diferencia) observada** en la **actividad económica**.
- **Montevideo** y la **presencia de un puerto** presentan **asociaciones positivas**.
- **Universidad**, **desempleo** y la **pertenencia al área metropolitana** presentan **asociaciones negativas**.

- Ninguno de los factores resulta **estadísticamente significativo** al **5%**

→ No tenemos evidencia estadística suficiente para afirmar que sus **coeficientes** sean **distintos de cero**.

```
                    ic95_inf  ic95_sup
Universidad (%)       -1.055     0.703
Desempleo (%)         -0.658     0.112
Puerto                -0.341     1.850
Montevideo            -1.665     5.163
Área metropolitana    -1.328     0.758
R² = 0.30 | 247 obs | 19 deptos
```

## ¿Qué significa que $R^2 = 0.30$?

- Significa que el modelo logra explicar el **30%** de la **variación de la actividad económica** observada en los datos.
- El **70%** restante queda **sin explicar** por el modelo.
- No significa que los cinco factores causen el 30% de la actividad económica.

## ¿Qué significa que ningún factor sea estadísticamente significativo?

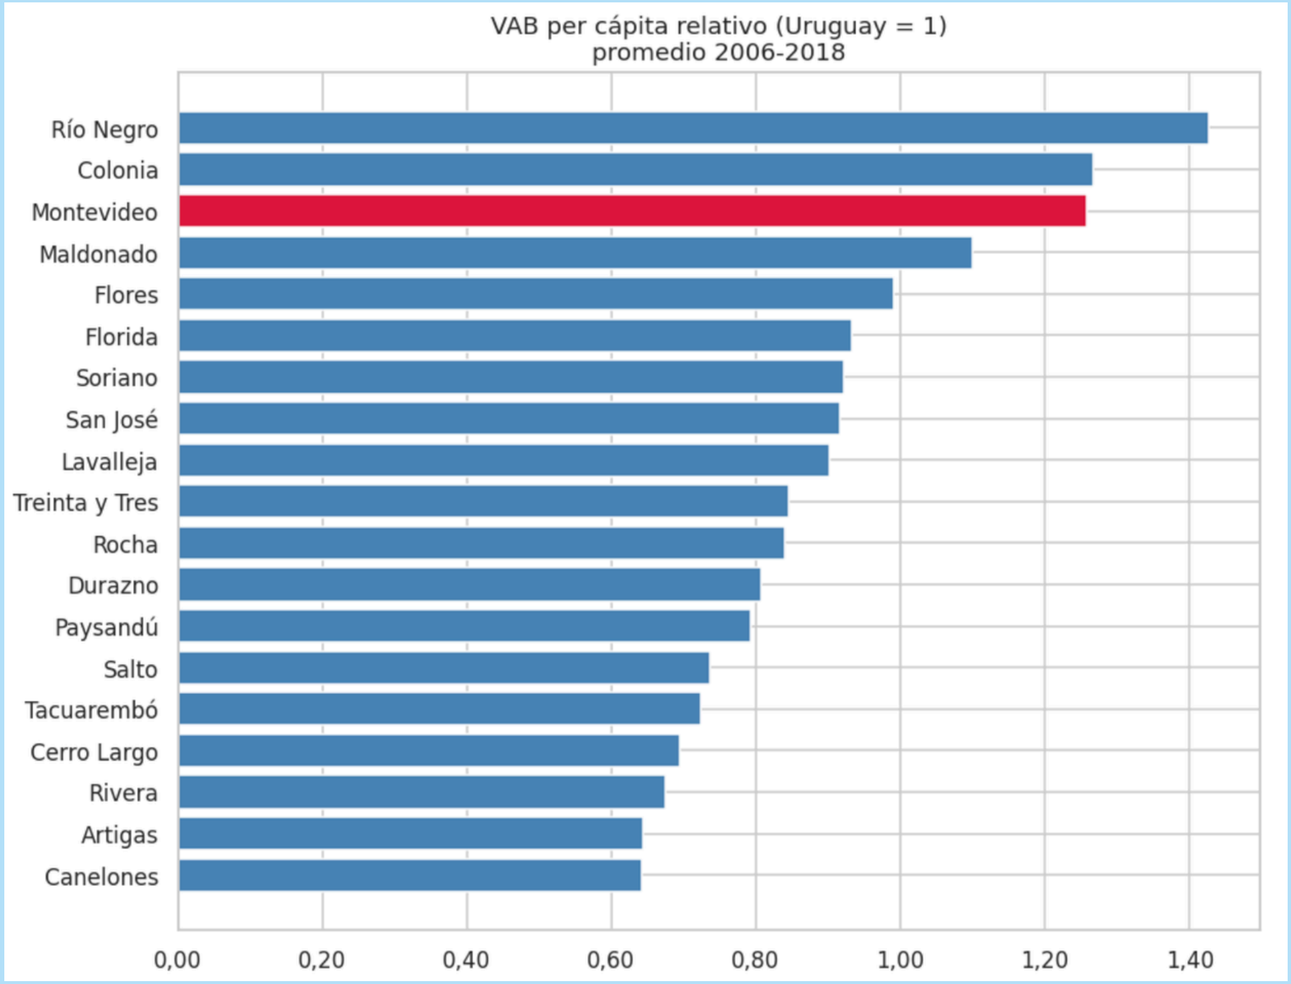
- Que todos tienen un **p-valor > 0.05**.
- Por lo tanto, no tenemos suficiente evidencia estadística para afirmar que sus coeficientes sean diferentes de 0.
- Es decir: **no podemos asegurar que las variables realmente estén relacionadas con la actividad económica**.

## ¿Por qué incluimos Montevideo y el Area Metropolitana por separado?

- Porque **Montevideo concentra mucha actividad económica**, mientras que **Canelones** y **San José** tienen una **relación especial con la capital**.
- Por ejemplo, gran parte de la población de estos departamentos trabaja en **Montevideo**, por lo que la **producción** puede registrarse en un departamento **diferente al de residencia**.

**Conclusión**: El modelo estima asociaciones entre distintos factores y la actividad económica, pero su capacidad explicativa es limitada y ninguna de estas asociaciones resulta estadísticamente significativa. Esto sugiere que existen otros factores relevantes que no estamos considerando.

# 8. Ranking de actividad por departamento (promedio del período)

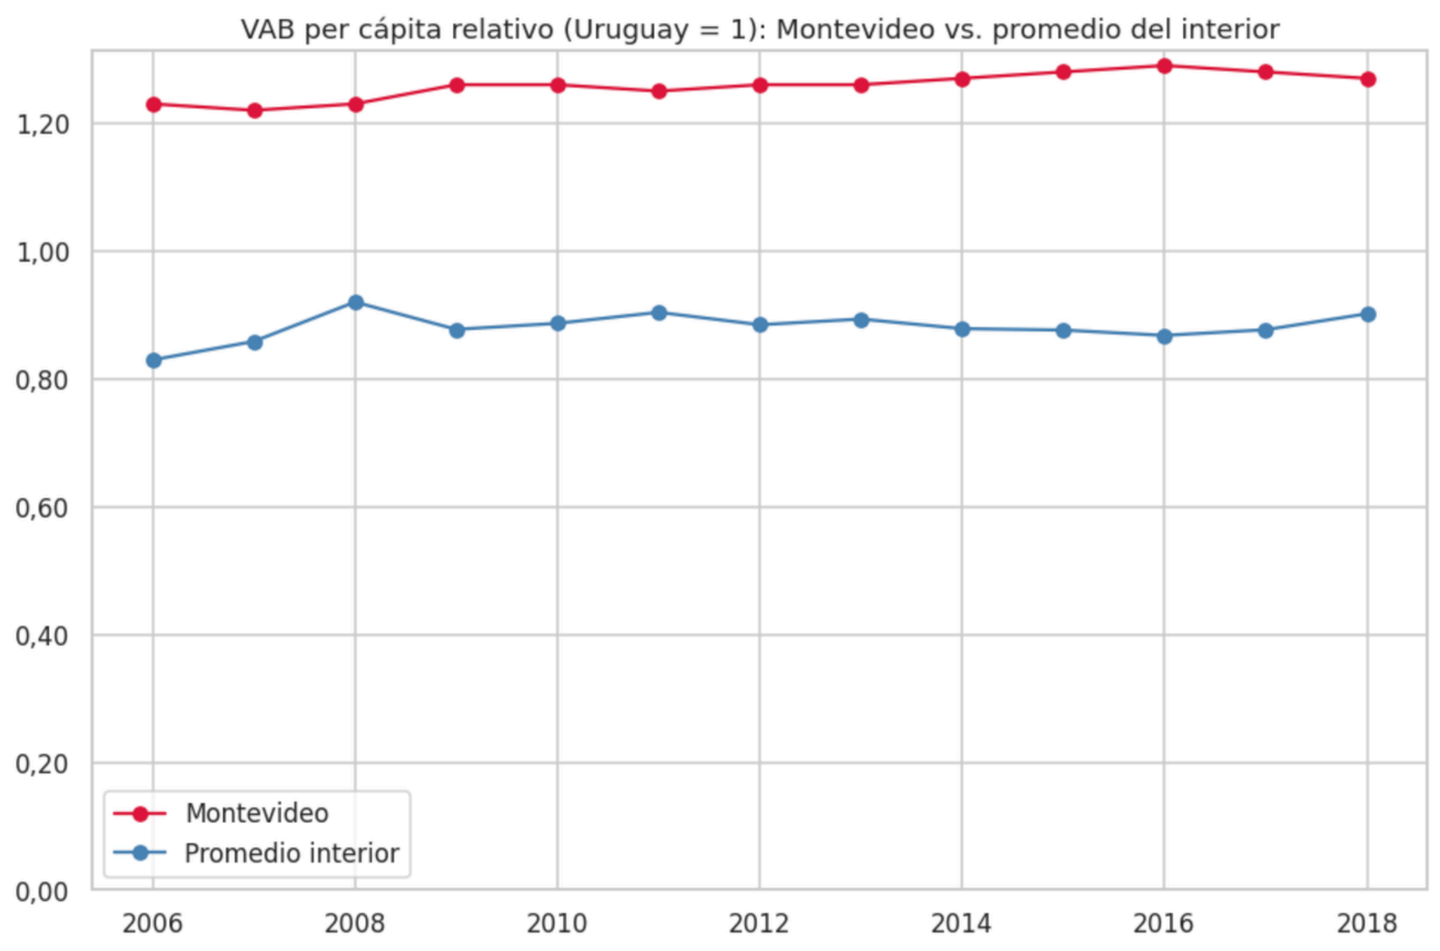



• **Río Negro lidera** el ranking, con un VAB per cápita relativo 43% superior al promedio nacional, seguido por **Colonia y Montevideo.**

• Solamente **4 de los 19** departamentos presentan un VAB per cápita relativo superior al promedio nacional (Uruguay = 1).

•Se observan **diferencias importantes** entre los departamentos del interior, evidenciando una marcada heterogeneidad territorial.

# 9. Evolución de la actividad: Montevideo vs promedio interior

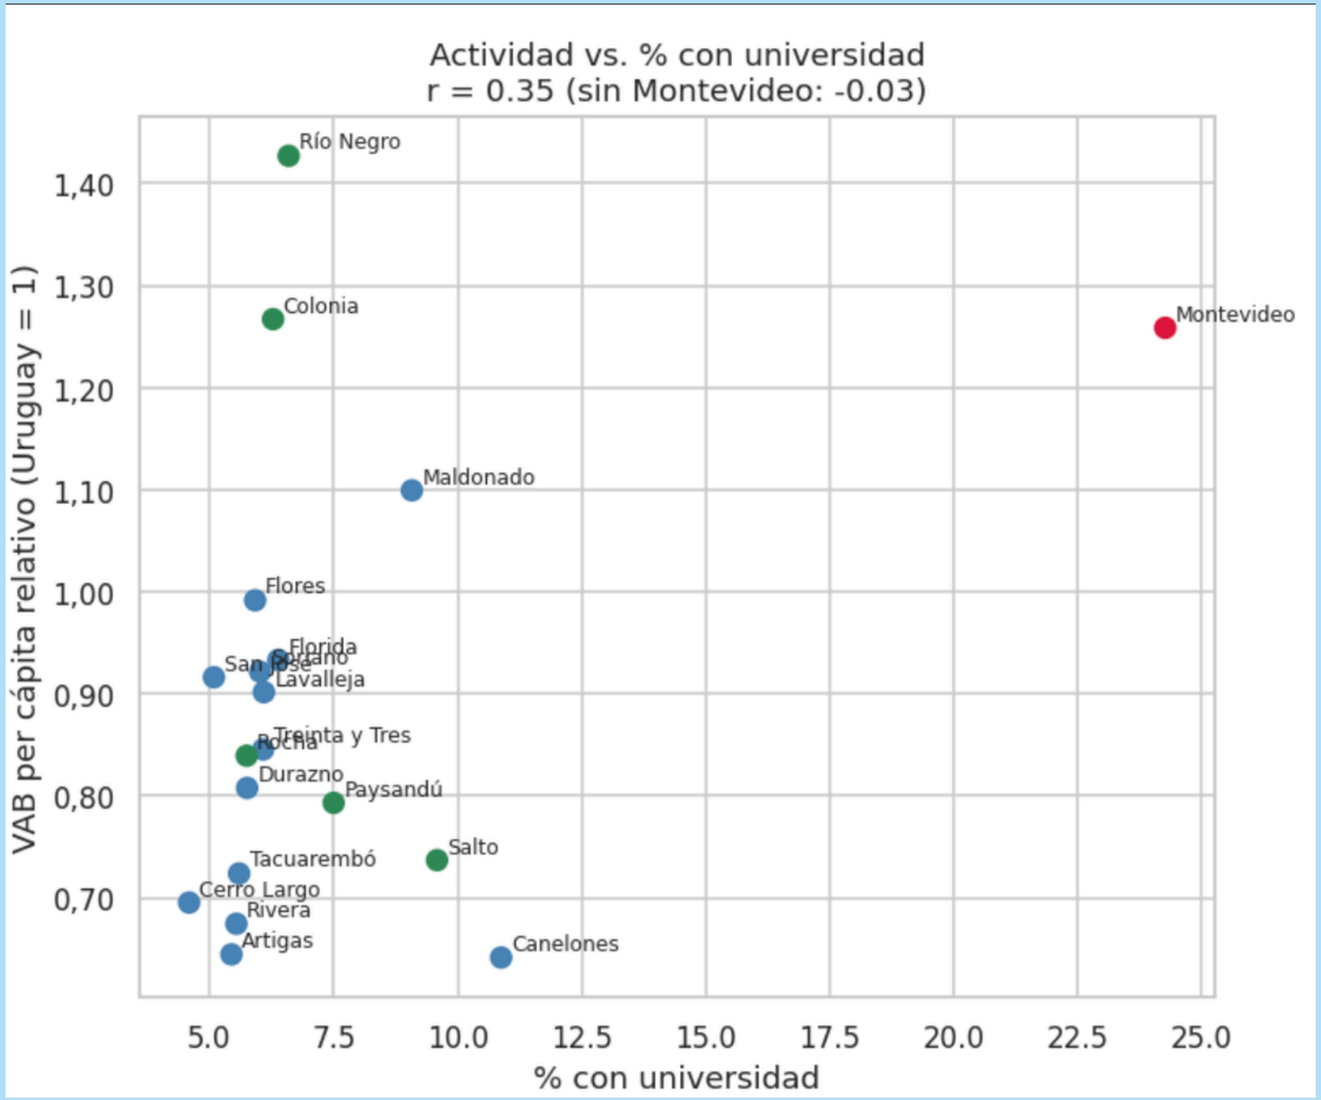



- Analizamos cómo evolucionó la **actividad económica per cápita** de **Montevideo** en comparación con el **promedio de los departamentos** del interior entre **2006** y **2018**.

- Vemos que **Montevideo** se mantiene **siempre por encima** del **interior**.

- **Convergencia**: la **diferencia** entre ambos se **redujo** levemente: **x1.48 → x1.41**

# 10. Actividad vs. educación (promedios por departamento)

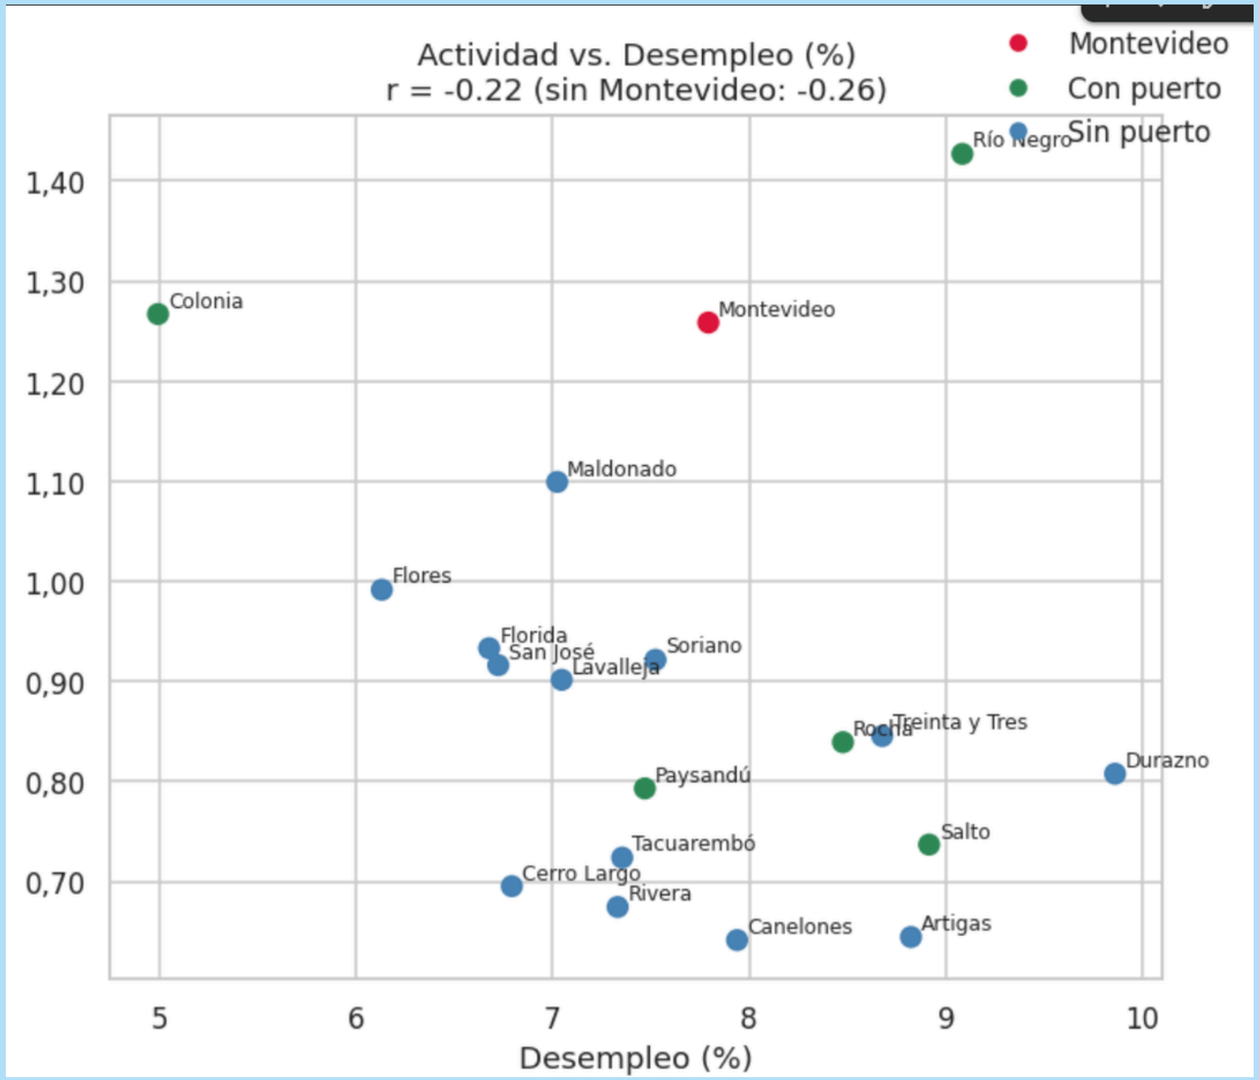



**¿Los departamentos con más educación tienen más actividad económica?**

**Educación y actividad: r=0,35** (correlación moderada), pero sin Montevideo cae a **-0,03.**

**La relación desaparece:** la correlación se explica por la capital, donde coinciden mayor educación y actividad económica. **En el interior, la educación no se asocia con mayor VAB per cápita.**

# 11. Actividad vs. desempleo (promedios por departamento)




**¿Los departamentos con más desempleo tienen más actividad económica?**

**Desempleo: r = −0,22 (débil)**. Hay una leve tendencia a que los departamentos con más desempleo tengan menos actividad, pero es muy débil: **el desempleo no distingue a los departamentos que producen *más* de los que producen *menos*.**

# 12. Actividad vs. desempleo

**¿Los departamentos con más desempleo tienen más actividad económica?**

**Desempleo y actividad económica**

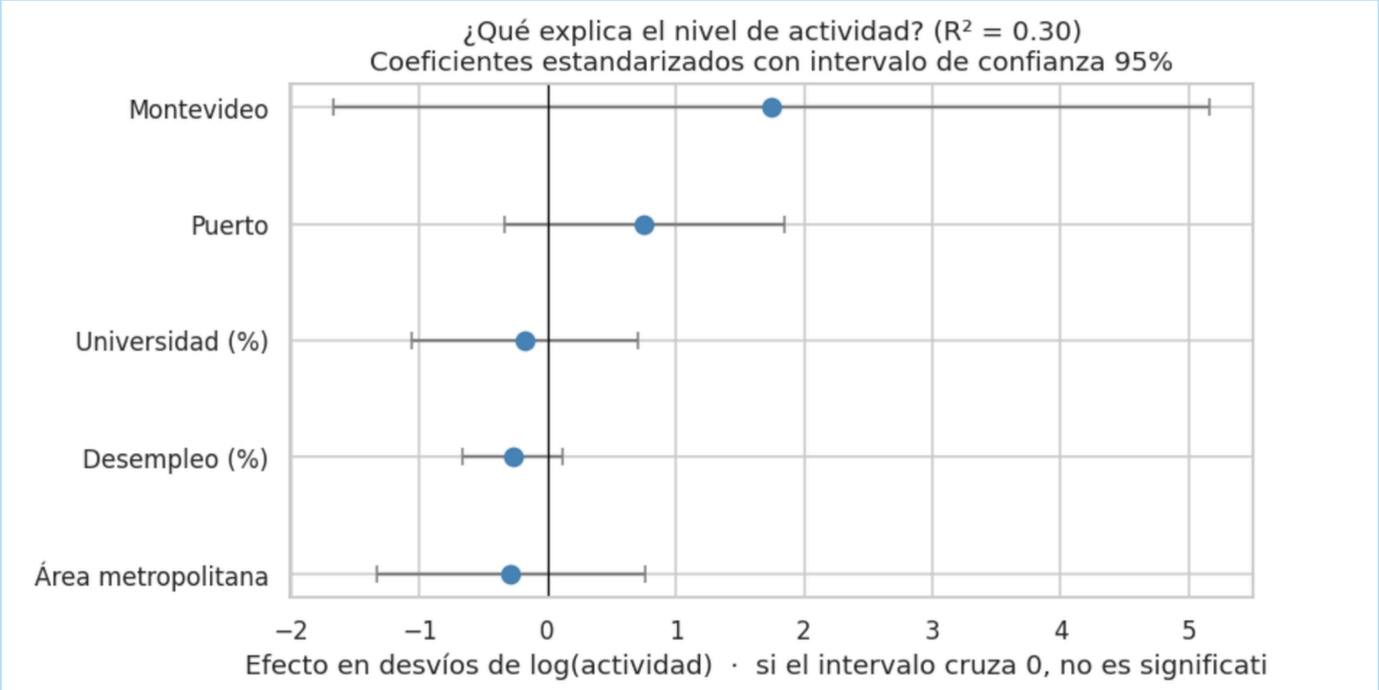
- **Entre departamentos**: la relación es débil (**r=-0,22**). Ej.: Río Negro combina desempleo alto (9,1 %) con la mayor actividad (1,43). Los departamentos con más desempleo no son sistemáticamente los de menor actividad.

***Razones:***

- **Migración**: las personas pueden trasladarse donde hay empleo, bajando el desempleo y aumentando la producción de otro departamento.

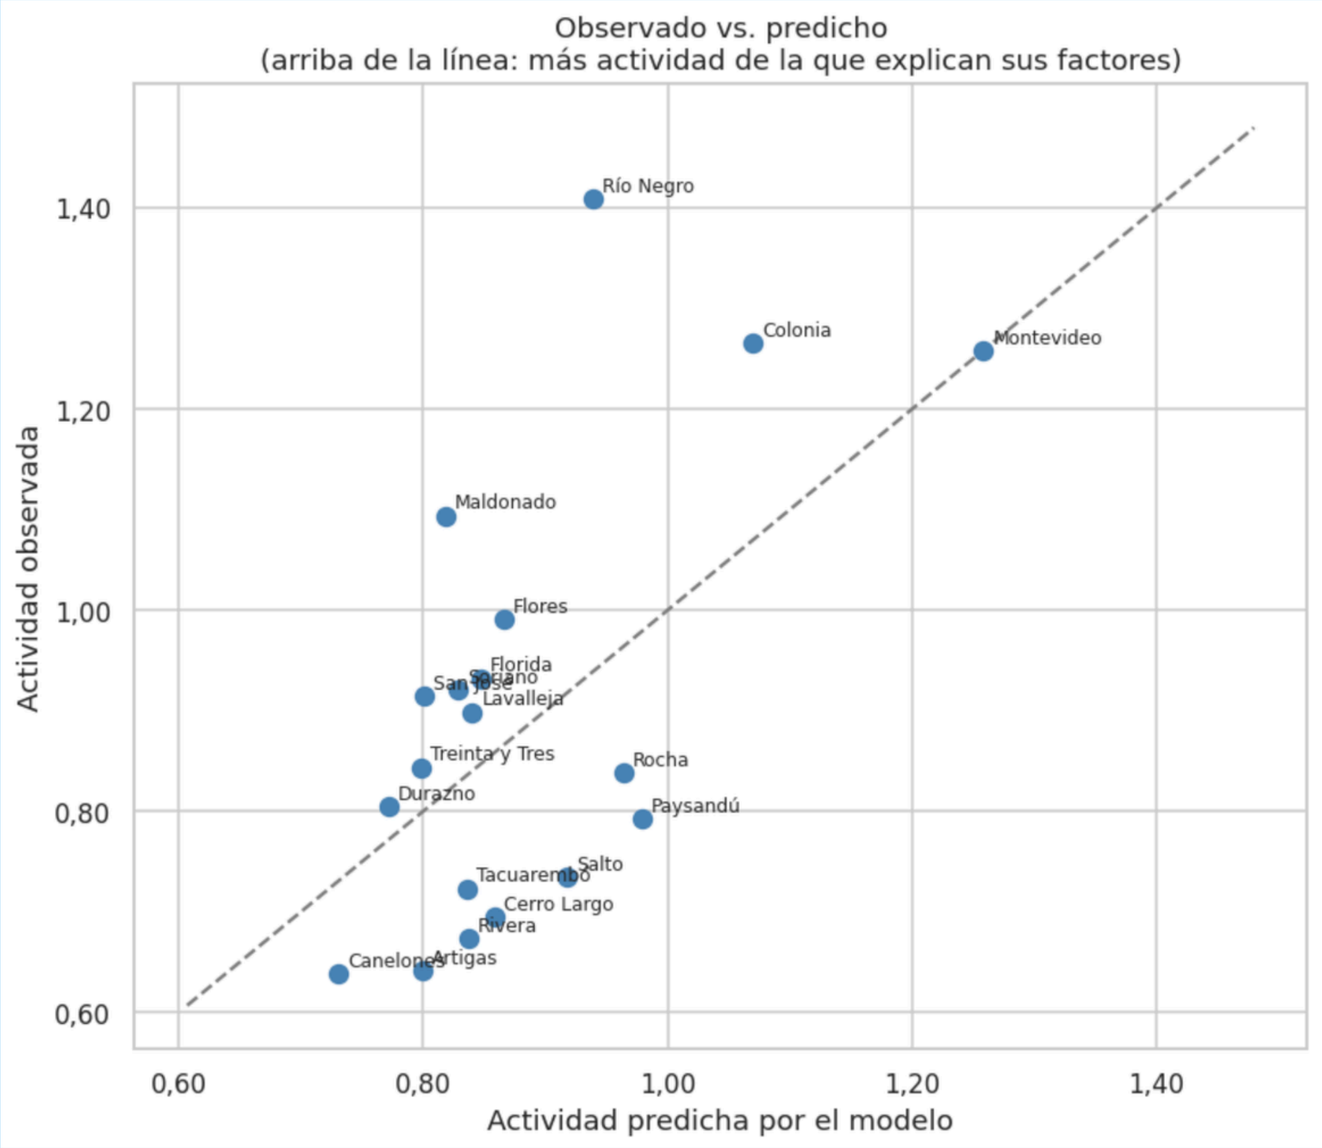
- **Especialización productiva:** sectores como la celulosa y el agro generan mucho valor con relativamente poca mano de obra.

# 13. Coeficientes estandarizados e intervalos de confianza (95%)




- **Montevideo y la presencia de puerto** presentan los mayores coeficientes estandarizados positivos del modelo.
- **Educación universitaria, desempleo y área metropolitana** presentan coeficientes negativos, aunque de menor magnitud.
- Todos los **intervalos de confianza incluyen el cero**, por lo que ningún factor resulta estadísticamente significativo al 5%.

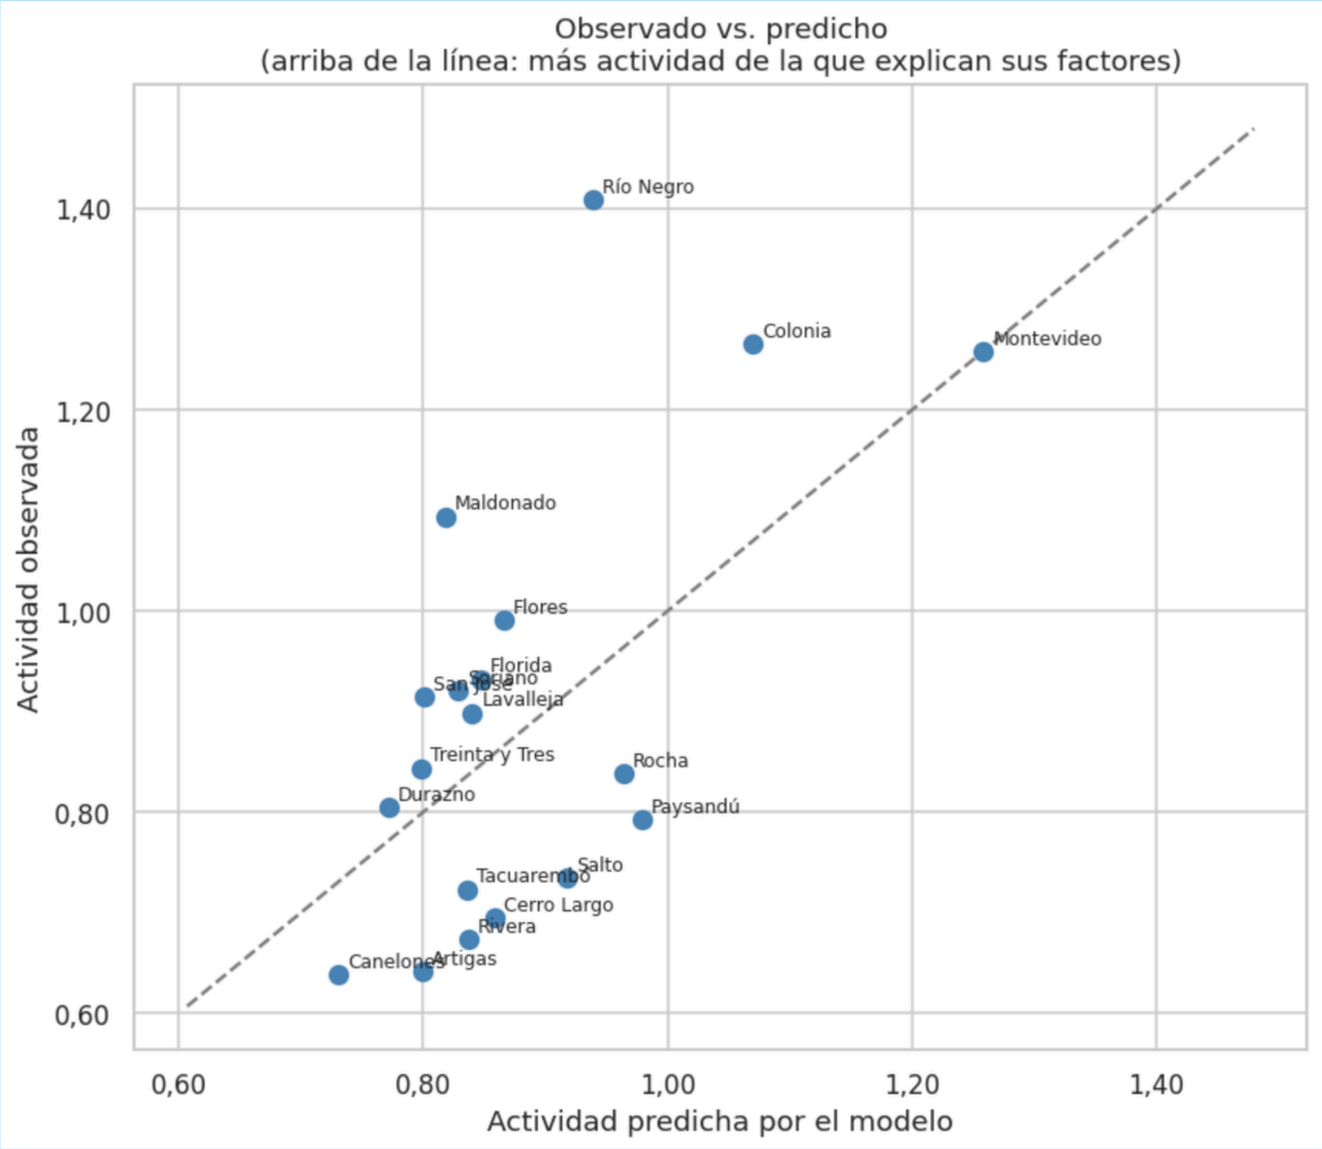
# 14. **Observado vs predicho por el modelo**




• Comparamos la **actividad económica real** con la **estimada (promedio) por el modelo** para cada departamento.

• La **línea diagonal** representa una **estimación perfecta**: cuánto más **cerca** esté un punto, **menor** es el **error** del modelo.

# Principales resultados




- **Precisión del modelo**: **4** de 19 departamentos representan un desvío inferior o igual al 10%.

- **Mayor desvío positivo**: **+50%** en Río Negro.

- **Mayor desvío negativo**: **–20%** en Salto.

→ Existen **diferencias territoriales** que las variables del modelo no logran explicar completamente.

## ¿Qué significa que Río Negro esté por encima de la línea?

Que su **actividad económica real** es **mayor** a la que el modelo estima a partir de las variables explicativas. Podría haber factores económicos propios del departamento que el modelo no está captando.

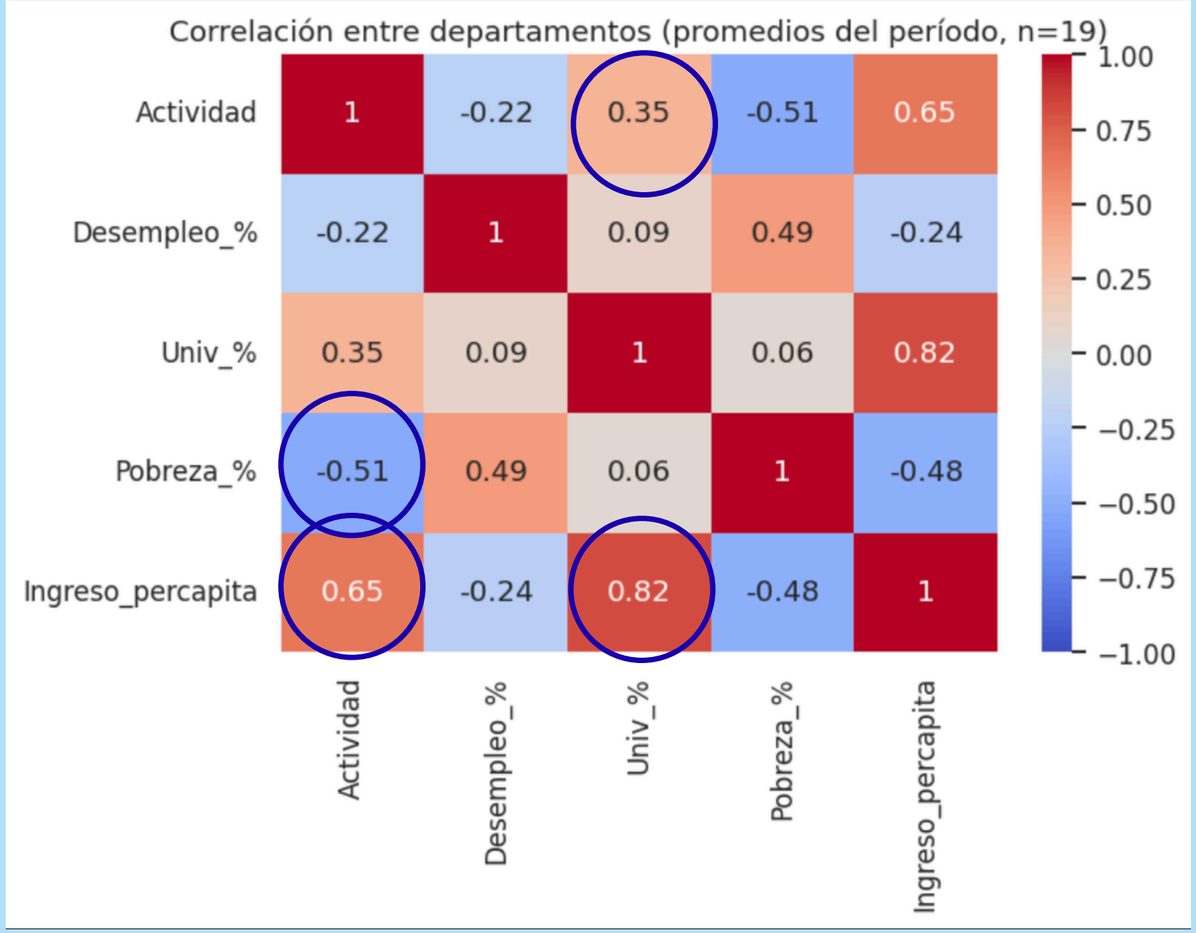
## ¿Y que Salto esté por debajo de la línea?

Lo **contrario**: según sus variables explicativas, el modelo estima una actividad **mayor** a la que **realmente se observa**.

## ¿Significa que el modelo es malo?

**No necesariamente**. Pero que solo **4** departamentos tengan errores de hasta el 10% indica que su capacidad para reproducir los promedios departamentales es limitada. Para evaluar su calidad general también habría que **considerar otros indicadores**, como el $R^2$ y el análisis de residuos.

# 15. **Correlaciones entre departamentos**



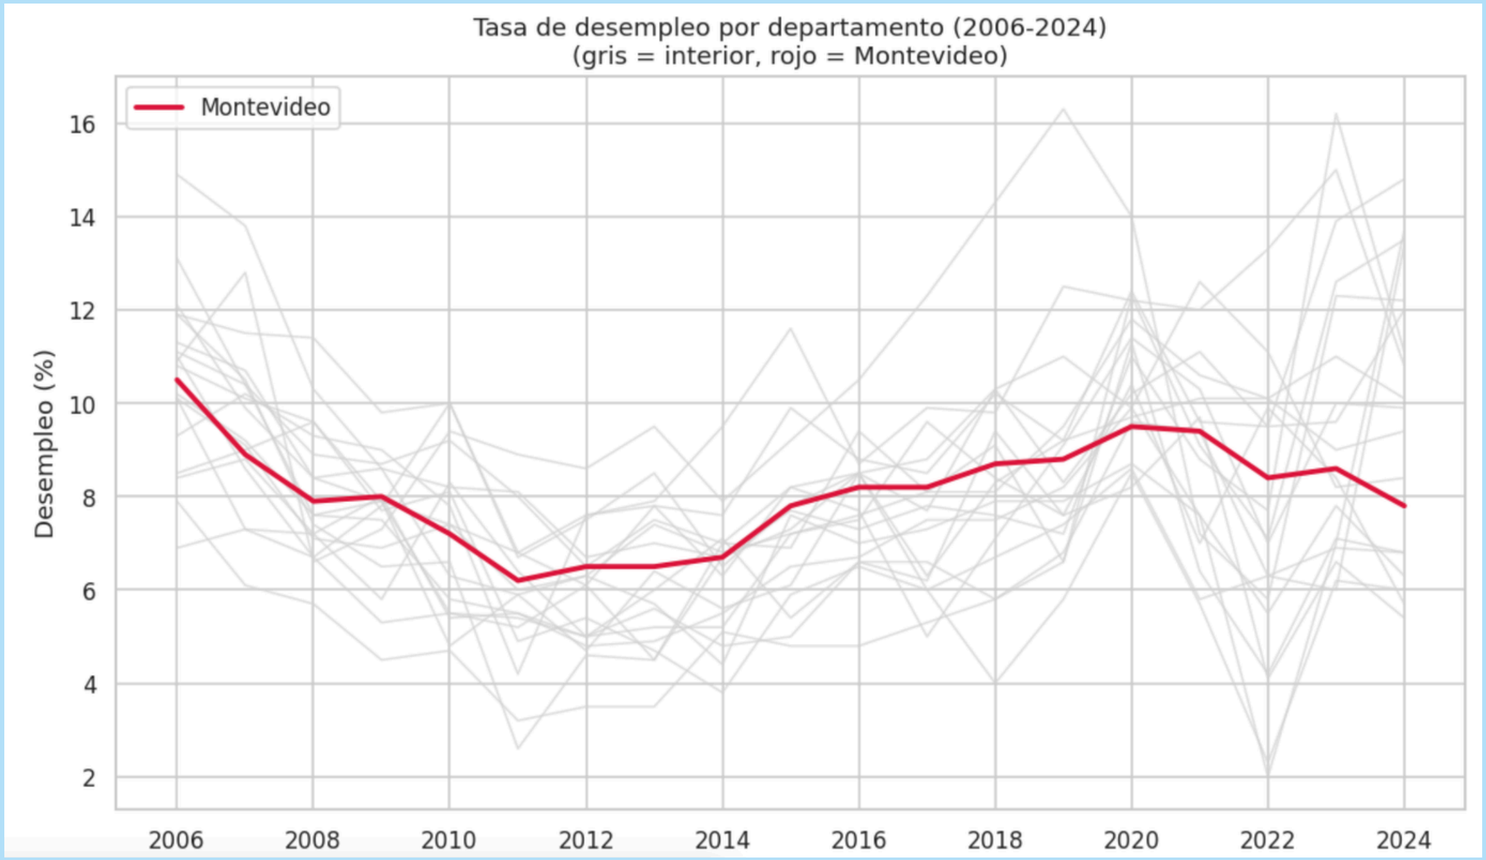

La **educación** se asocia fuertemente con el **ingreso de los hogares** (**r = 0,82**), pero mucho menos con la producción departamental (**r = 0,35**).

La **actividad** económica se vincula más con el **ingreso** (**0,65**) y la **pobreza** (**−0,51**) que con los factores laborales y educativos.

Las correlaciones son estables al descontar el ciclo económico común.

```
fig, ax = plt.subplots(figsize=(7, 5.5))
sns.heatmap(corr_entre, annot=True, cmap="coolwarm", center=0, vmin=-1, vmax=1, ax=ax)
ax.set_title("Correlación entre departamentos (promedios del período, n=19)")
guardar(fig, "06_heatmap_correlacion.png")
```

# 16. **Evolución del desempleo**

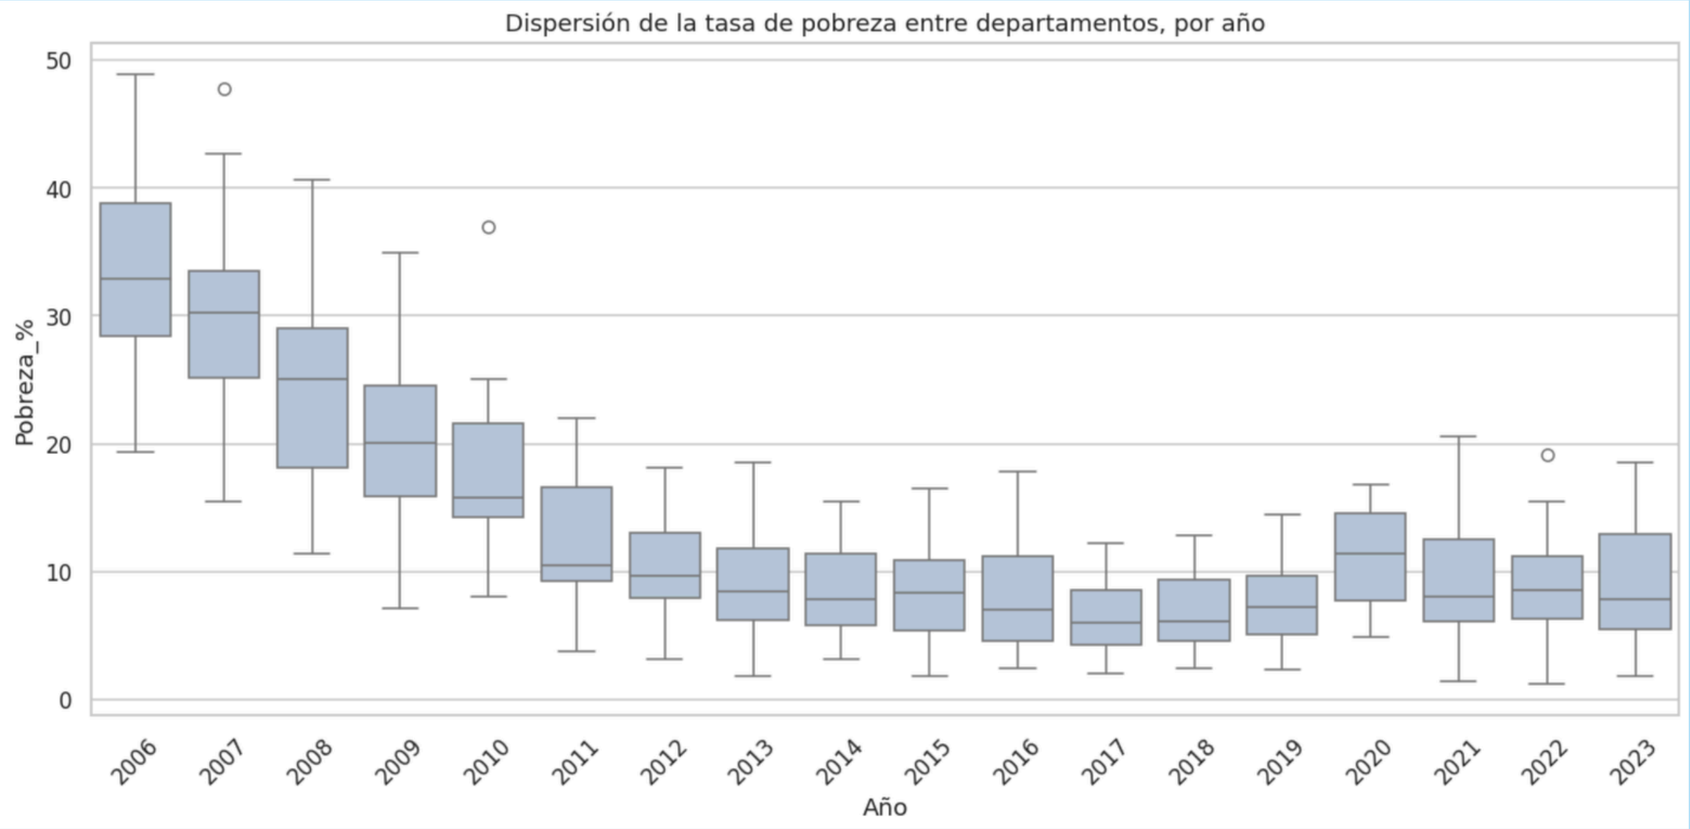



- El **desempleo en Montevideo disminuyó entre 2006 y 2011**, **aumentó** nuevamente hasta **2020** y mostró una reducción posterior.

- Se observan **diferencias importantes en las tasas y trayectorias del desempleo** entre los departamentos del interior, especialmente en los últimos años.

- La evolución del desempleo **no fue uniforme entre departamentos,** evidenciando diferencias territoriales en el mercado laboral.

# 17. **Dispersión de la pobreza entre departamentos**




→ **Reducción importante** de la **pobreza**: la **mediana** pasó de **32,9%** en 2006 a **7,8%** en 2023.

→ Las **cajas** se vuelven **más pequeñas**: las **diferencias entre departamentos** también **disminuyeron**.

• Analizamos como **evolucionó** la **pobreza** entre los departamentos de Uruguay desde 2006 hasta 2023.

• El **gráfico de cajas** nos permite observar tanto el **nivel de pobreza** como las **diferencias entre departamentos** en cada año.

## ¿Cómo interpretar el gráfico?

- **Mediana** = valor que deja a la **mitad** de los departamentos por encima y a la otra mitad por debajo.
- **Caja** = contiene el **50% central** de los departamentos. Cuanto más alta sea, mayores son las diferencias entre sus tasas de pobreza.
- **Bigotes** = muestran los valores extremos que no se consideran atípicos.
- **Puntos aislados** = representan departamentos con tasas de pobreza inusualmente altas o bajas respecto al resto.

## ¿El rango intercuartílico pasó de 10.4 a 7.4, qué significa?

- El **rango intercuartílico** es la **diferencia** entre el **tercer** y el **primer** cuartil → mide qué tan separados están los **niveles de pobreza** del **50% central** de los departamentos.
- Por lo tanto, los **departamentos centrales** de la distribución tienen **tasas de pobreza más parecidas que antes**. Eso es evidencia de una **reducción de la dispersión absoluta**, aunque no significa que hayan desaparecido las desigualdades.

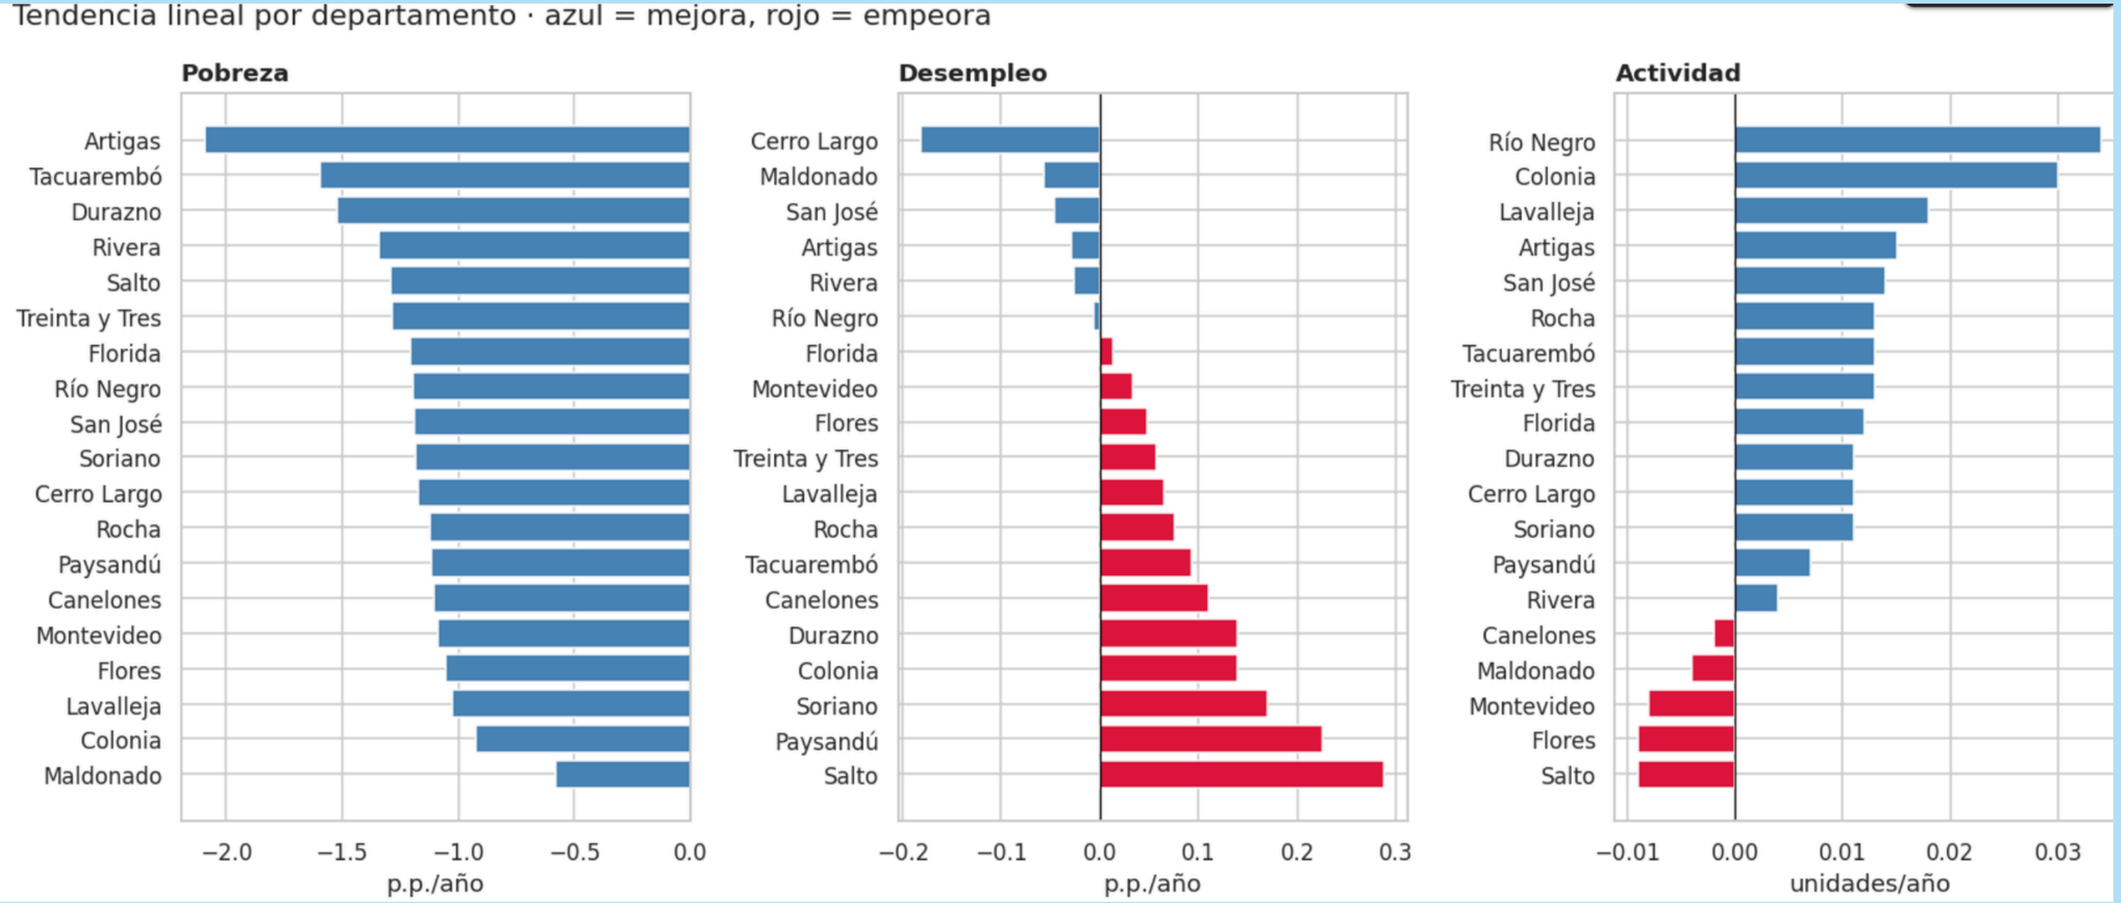
## ¿Qué pasó en 2020?

- La **mediana aumentó** de **7,2%** en 2019 a **11,4%** en 2020, es decir, **4,2** puntos porcentuales.
- Este aumento coincide con la **pandemia de COVID-19** y es consistente con su impacto económico, aunque el gráfico por sí solo no demuestra causalidad.

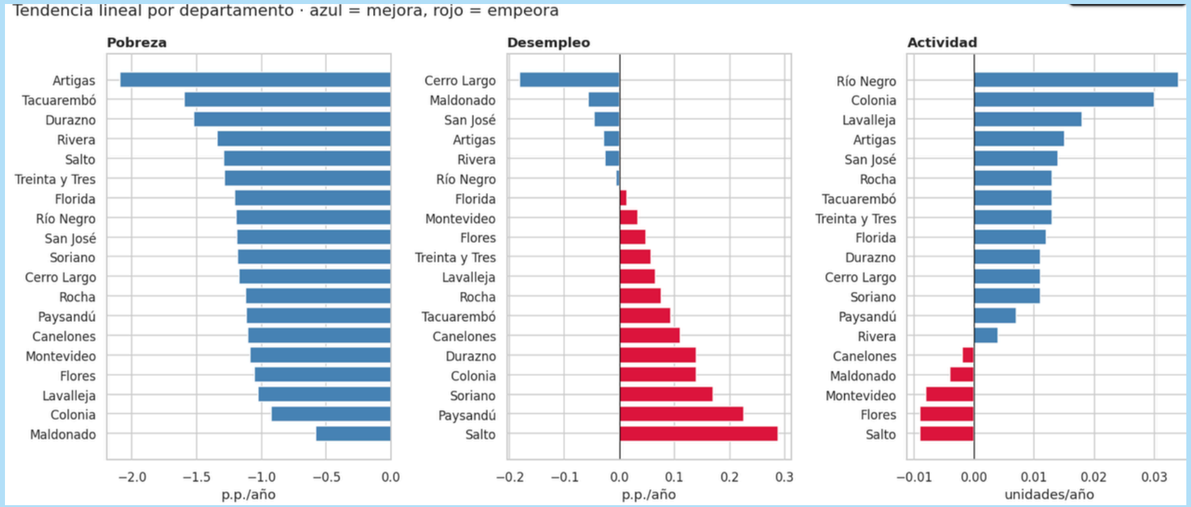
## → Conclusiones

Entre 2006 y 2023, Uruguay logró una **reducción importante** de la **pobreza** y una **disminución** de las **diferencias absolutas entre departamentos**. Sin embargo, la **pandemia** interrumpió temporalmente esta mejora y **todavía persisten desigualdades territoriales**.

# 18. **Tendencias por departamento**



# 19. **Tendencias por departamento**

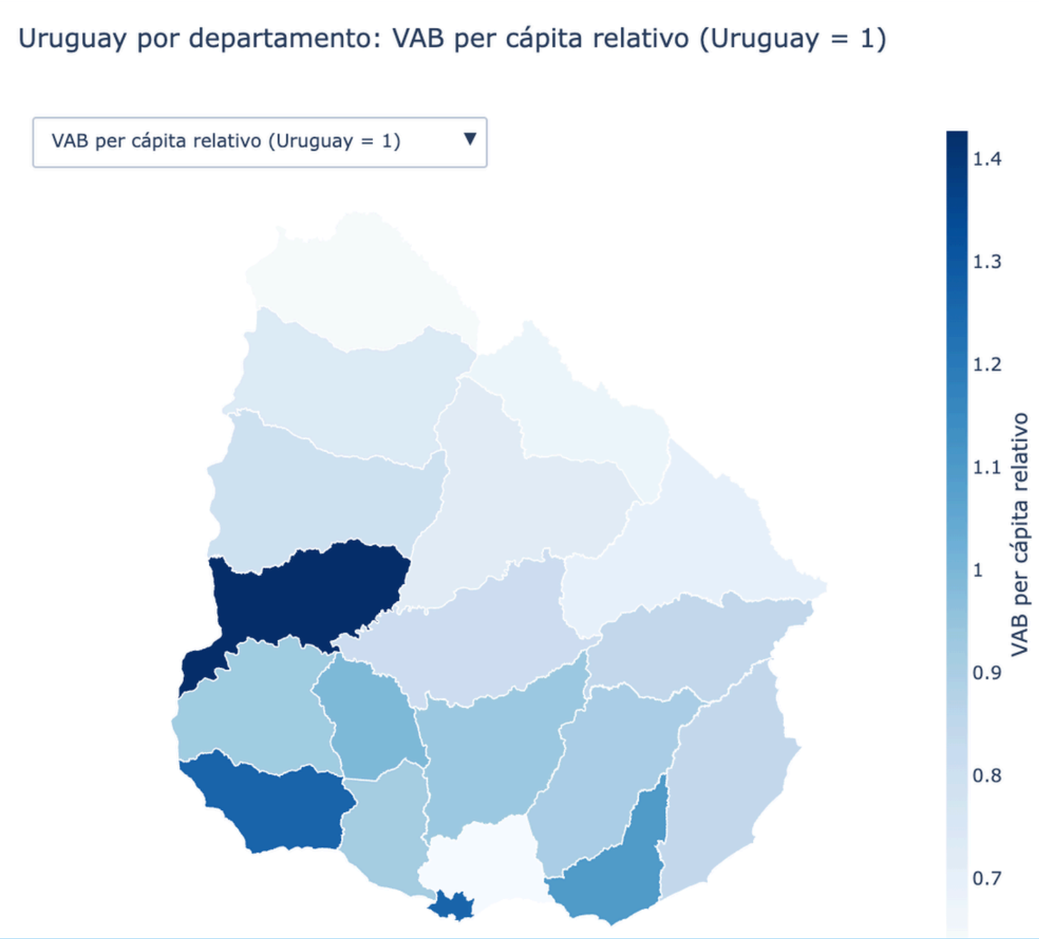



**Impacto limitado de los factores sociales:** las variaciones en pobreza y desempleo muestran una **relación débil** con el crecimiento de la actividad económica (**r = -0,18 y -0,15**).

**Predominio de factores productivos:** el crecimiento de la actividad en Río Negro y Colonia parece estar más vinculado a **inversiones y sectores productivos específicos que a mejoras sociales.**

La mejora social no garantiza mayor actividad: **la pobreza cayó en todos los departamentos,** incluso en algunos que perdieron peso en la actividad económica.

# 20. **Mapa interactivo**




- Se identifica un **patrón territorial norte–sur:** los departamentos ubicados más al norte tienden a presentar menor actividad económica por habitante (r = -0,52).
- La **mitad sur presenta mayor actividad económica promedio que la mitad norte** (0,98 frente a 0,82).
- Los **departamentos fronterizos con Brasil** se concentran en posiciones bajas del ranking, con un puesto promedio de 15,2 sobre 19.

# ¡GRACIAS!

